กลุ่ม **Phoebe**
1. นาย คงยุทธ คล่องแคล่ว รหัสนิสิต 6620501303
2. นาย ภูดิสพัฒน์ ศรีสุพรรณ์ รหัสนิสิต 6620503535

Full Proposal

1. Summary of Changes

- output ที่เป็น mobile application
  อาจไม่สามารถทดสอบกับสายโทรจริงเนื่องด้วยข้อจำกัดด้านการเป็น emulator ดังนั้นการ demo บน mobile emulator จะทดสอบกับไฟล์เสียงบทสนทนา

2. Project Overview

2.1. ชื่อโครงงาน : อย่าเอาเงินชั้นไป - Scam Call Alert

2.2. Pain Point, หลักการและเหตุผล :

มิจฉาชีพเปลี่ยนเบอร์โทรได้ตลอดเวลา วิธีการเดิมอย่างการใช้แอปตรวจเบอร์ที่ต้องการการอัพเดทฐานข้อมูลเบอร์โทรของมิจฉาชีพอยู่เสมออาจไม่เป็นปัจจุบัน จึงประยุกต์ใช้ Machine Learning เรียนรู้ datasets ที่เกี่ยวกับบทสนทนาของมิจฉาชีพเพื่อทำการ classify/predict ว่าคู่สนทนามีแนวโน้มเป็นมิจฉาชีพหรือไม่

2.3. วัตถุประสงค์ :

1. สร้างโมเดลที่มีความสามารถในการจำแนกข้อความบทสนทนาว่ามีแนวโน้มเป็นมิจฉาชีพหรือไม่
2. สร้างแอปพลิเคชันมือถือที่สามารถวิเคราะห์คู่สนทนาว่ามีแนวโน้มเป็นมิจฉาชีพหรือไม่จากข้อความในบทสนทนา

2.4. ขอบเขต :

1. วิเคราะห์บทสนทนาภาษาไทย โดยถอดเสียงเป็นข้อความแล้วจำแนกเป็น Scam หรือ Not Scam
2. แจ้งเตือนผู้ใช้หากโมเดล predict ว่าเป็น Scam ไม่ครอบคลุมการบล็อกสายโทรศัพท์

2.5. ผลลัพธ์ที่คาดหวัง :

1. ได้โมเดลที่จำแนกบทสนทนาภาษาไทยเป็น Scam หรือ Not Scam
2. ได้ต้นแบบแอปบน mobile emulator ที่ใช้โมเดลนั้นถอดข้อความจากเสียงสนทนาและการแจ้งเตือนความเสี่ยง

3. Problem Formulation

- **Machine Learning Problem :** Fraud Call Detection
  (จำแนกมิจฉาชีพจากบทสนทนาทางการโทร)
- **Input :** ข้อความ (text) ที่ถอดจากเสียงบทสนทนาที่กำลังดำเนินอยู่ด้วย STT model
- **Output :** เป็นสายโทรศัพท์จากมิจฉาชีพ หรือ ไม่เป็นสายโทรศัพท์จากมิจฉาชีพ (Scam / Not Scam classification)

4. Data and Dataset

ชุดข้อมูล	ลักษณะ	วิธีการเก็บข้อมูล	บทบาทในโครงงาน
1) Scam Dialogue Thai Translated [1]	1,280 บทสนทนา; 8 ประเภท ประเภทละ 160; label ที่ให้มาสมดุล 640 Scam / 640 Not Scam	ต้นฉบับเป็นบทสนทนาจำลองภาษาอังกฤษ [4] สร้างจาก Llama 3, ฉบับแปลไทยระบุแปลด้วย Claude Sonnet 4.6	ใช้เป็นชุดข้อมูลหลักเนื่องจากมีงานวิจัยอ้างอิงถึง [3]
2) Thai Call Center Call Log Dataset [2]	198 samples; แบ่งเป็น 5 ประเภท: Scam 73, General 49, Official 37, Verification-call 26, Unknow 13	บทสนทนาภาษาไทยจำลอง แบ่งบทพูดเป็น [Call] และ [User] ระหว่างคู่สนทนา	ใช้เป็นชุดข้อมูลเสริม เพราะไม่มีงานวิจัยรองรับแล้วเปรียบเทียบผล evaluation ว่าดีขึ้นหรือไม่

4.1. การกำหนด label

ใช้ label Scam/Not Scam โดย

- Scam Dialogue Thai Translated มี label เป็น Scam / Not Scam อยู่แล้ว
- Thai Call Center Call Log Dataset ทำการ label ให้คลาส Scam เดิมยังคงอยู่ และคลาสอื่น ๆ เป็น Not Scam

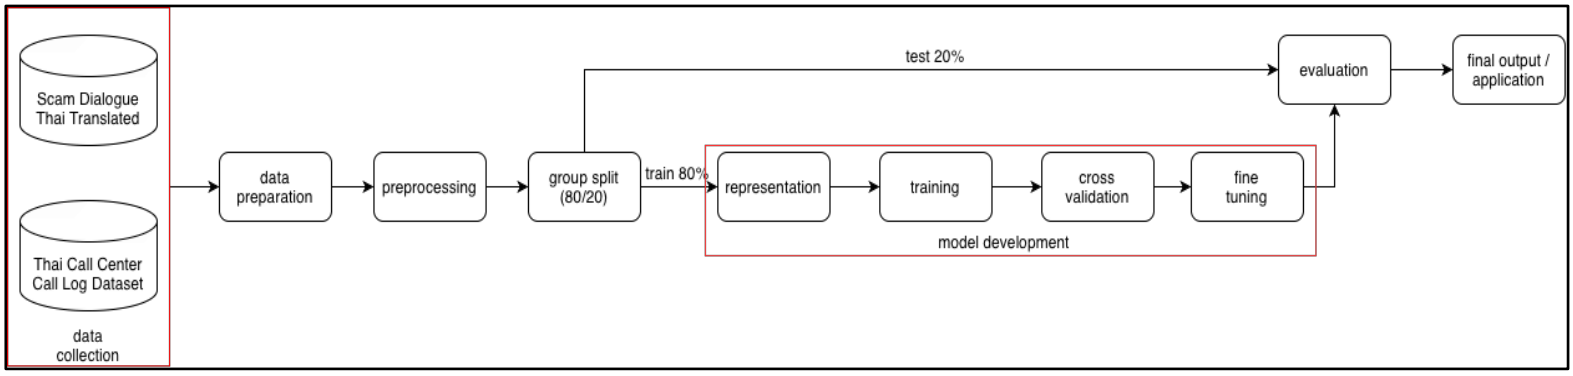
4.2. การแบ่งชุดข้อมูล

แบ่งชุดข้อมูลเป็น 80/20 (train/test) ใช้ K-fold cross-validation เนื่องจากจำนวน samples ไม่มาก พร้อมทั้งรักษาสัดส่วนของ Scam / Not Scam ในทั้งชุด train และ test

4.3. ข้อจำกัดหรือปัญหาที่คาดว่าจะพบ

- ชุดข้อมูลที่ถูกแปลมาจากต้นฉบับภาษาอังกฤษอาจอาจใช้ภาษาที่แปลก ไม่เป็นธรรมชาติ
- ข้อมูลทั้งสองชุดเป็นบทสนทนาจำลอง ไม่ใช่สายจริง
  ผลทดสอบจึงยังบอกไม่ได้ว่าแอปจะตรวจจับมิจฉาชีพจากสายจริงได้ดีแค่ไหน

5. Proposed Pipeline



ขั้นตอน	วิธีที่คาดว่าจะใช้	ผลลัพธ์
Data Collection	รวบรวมชุดข้อมูล Scam Dialogue Thai Translated และ Thai Call Center Call Log	ข้อมูลจากชุดข้อมูลหลักทั้งสอง
Data Preparation	ชุดข้อมูล 1) ใช้ label Scam / Not Scam ที่มีอยู่แล้ว ส่วนชุด 2) คงคลาส Scam เดิมไว้ และรวมคลาสอื่นเป็น Not Scam และจัดการข้อมูลซ้ำหรือไม่สมบูรณ์ หากพบ label ที่กำกวมให้ไม่นำมาใช้	ชุดข้อมูลที่จัดรูปแบบและ label แล้ว
Preprocessing	ปรับรูปแบบข้อความและบทบาทผู้พูดให้สม่ำเสมอ โดยรักษาลำดับการสนทนาและเนื้อหาสำคัญไว้	Transcript ที่พร้อมป้อนเข้าโมเดล
Feature Engineering / Representation	ใช้ tokenizer ของแต่ละโมเดลแปลง transcript เป็น input ตามรูปแบบที่โมเดลต้องการ	Input สำหรับโมเดลแต่ละตัว
Model Development	ทดลองฝึก WangchanBERTa, PhayaThaiBERT, HPLT 3.0 GPT-BERT Thai และ XLM-RoBERTa-base กับชุดข้อมูล	โมเดลที่ฝึกแล้วและผลทำนาย
Evaluation	เปรียบเทียบโมเดล ประเมินด้วย Precision, Recall, F1-score, Accuracy และ Confusion Matrix โดยเน้นผลของกลุ่ม Scam	ผลเปรียบเทียบและโมเดลที่เลือก
Final Output / Application	โมเดลแสดงผล Scam / Not Scam จาก Transcript และแสดงคำเตือนเมื่อพบ Scam โดยออกแบบให้ต่อยอดกับ Speech-to-Text ได้	ผลตรวจจับและแนวทางต่อยอด

6. Experimental Design and Evaluation

6.1. โมเดลที่จะทดลอง

WangchanBERTa [5], PhayaThaiBERT [6], HPLT 3.0 GPT-BERT Thai [7] [8] และ XLM-RoBERTa-base [9] เพิ่มเป็นโมเดลหลายภาษา

6.2. การแบ่งชุดข้อมูล

แบ่งเป็น 80/20 ใช้ cross-validation, group split (ตามหัวข้อ 4.2.)

6.3. Evaluation metrics

Precision, Recall, F1-score, Accuracy และ Confusion Matrix โดยเน้น Recall และ F1-score ของกลุ่ม Scam

Final candidate จะเลือกโมเดลที่ให้ผลดีกว่าตัวอื่น พร้อมตรวจว่าทำงานร่วมกับ Speech-to-Text ได้โดยมีความหน่วง (latency) ที่ยอมรับได้ (ใกล้เคียง real-time)

7. Implementation Plan

7.1 ตารางแผนการดำเนินงาน

ช่วงของงาน	บทบาทและหน้าที่	งานที่ได้รับมอบหมาย
1. เตรียมข้อมูล	Data Scientist, สมาชิก 1	จัด label เป็น Scam / Not Scam ตัดข้อมูลซ้ำหรือกำกวม และเตรียมชุดข้อมูลโดยแบ่งตามบทสนทนา
2. ฝึกโมเดล	ML Engineer, สมาชิก 2	ฝึกและเปรียบเทียบโมเดล โดยใช้ชุดแบ่งข้อมูลเดียวกัน
3. ทดสอบ Speech-to-Text	STT/App Developer, สมาชิก 1 โดยมีสมาชิก 2 ช่วยเชื่อมโมเดล	ใช้ไฟล์เสียงที่เตรียมไว้ ทดสอบการถอดเสียงภาษาไทย และส่ง Transcript เข้าโมเดล
4. ทำต้นแบบบน Mobile Emulator	สมาชิก 1 และ 2	เชื่อมการเล่นไฟล์เสียง, Transcript, ผล Scam / Not Scam และการแจ้งเตือน โดยไม่รวมการบล็อกหรือดึงเสียงจากสายโทรศัพท์จริง
5. ทดสอบและสรุปผล	สมาชิก 1 และ 2	ตรวจการทำงานตั้งแต่เสียงถึงการแจ้งเตือน สรุป Metrics ความหน่วง และข้อจำกัดของระบบ

7.2 ความเสี่ยงและแนวทางรับมือ

ระบบตั้งแต่ถอดเสียงจนแสดงผลอาจช้าเกินไปสำหรับ real-time จึงทำแอปเป็นต้นแบบแนวคิด near real-time ด้วยไฟล์เสียงที่เตรียมไว้ และรายงานความหน่วงที่วัดได้

References

[1] thirdExec, *Scam Dialogue Thai Translated*, Hugging Face, 2026. ลิงก์

[2] Jxxn03X, *Thai Call Center Call Log Dataset*, Kaggle, 2025. ลิงก์

[3] I. Hossain *et al*., “AI-in-the-Loop: Privacy Preserving Real-Time Scam Detection...,” *PoPETs*, 2026, pp. 87–114. ลิงก์

[4] BothBosu, *Scam Dialogue*, Hugging Face, 2024. ลิงก์

[5] L. Lowphansirikul *et al*., “WangchanBERTa: Pretraining transformer-based Thai language models,” arXiv, 2021. บทความ

[6] P. Sriwirote *et al*., “PhayaThaiBERT: Enhancing a pretrained Thai language model with unassimilated loanwords,” *ACM TALLIP*, 2025. บทความ

[7] L. G. G. Charpentier and D. Samuel, “GPT or BERT: Why not both?,” arXiv, 2024. บทความ

[8] S. Oepen *et al*., “HPLT 3.0: Very large-scale multilingual resources for LLMs and MT,” arXiv, 2025. บทความ

[9] A. Conneau *et al*., “Unsupervised cross-lingual representation learning at scale,” in *ACL*, 2020, pp. 8440–8451. บทความ