**ชื่อกลุ่ม:** Phoebe

**สมาชิก:**

1. นาย คงยุทธ คล่องแคล่ว รหัสนิสิต 6620501303
2. นาย ภูดิสพัฒน์ ศรีสุพรรณ์ รหัสนิสิต 6620503535

**ชื่อโปรเจ็ค:** “อย่าเอาเงินชั้นไป - Scam Call Alert”

**ML Problem:** Fraud Call Detection

**1. ปัญหาและที่มา**

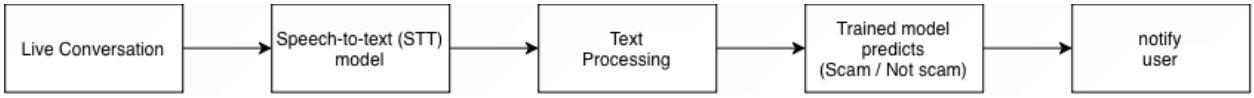
มิจฉาชีพเปลี่ยนเบอร์โทรศัพท์ได้ตลอดเวลา การบล็อกเบอร์ด้วยแอปพลิเคชันอย่างเช่น Whoscall จึงอาจไม่ทันท่วงที แต่สคริปต์การพูดหรือสูตรหลอกลวงที่สแกมเมอร์ชอบใช้มักใกล้เคียงกัน โครงงานนี้จึงเปลี่ยนจากการตรวจเบอร์แบบเดิม มาเป็นการประยุกต์ใช้ Machine Learning เพื่อตรวจจากเนื้อหาการสนทนา ว่าคู่สนทนานั้นเข้าข่ายพฤติกรรมมิจฉาชีพหรือไม่

สถิติความเสียหายจากสแกมเมอร์ในไทย:

- ความเสียหายสะสมกว่า **40,000 ล้านบาท** (จากกว่า 600,000+ คดี) โดยนับแค่คดีสะสมตั้งแต่ 1 ม.ค. 68 - 8 ก.ย. 69 (อ้างอิง https://www.thaipoliceonline.go.th/)
- Whoscall เผยรายงานในปี 2024 ว่าคนไทยคิดเป็น **28% (1 ใน 4) เคยตกเป็นเหยื่อ ของมิจฉาชีพ** โดยโทรศัพท์เป็นวิธีการที่ถูกใช้มากที่สุด (อ้างอิง https://kasets.art/CrvO4a)

**2. แนวทางการแก้ปัญหา**

**Main idea:** แปลงเสียงบทสนทนา -> ข้อความ -> ส่งให้ trained model predict ว่าเป็น scam หรือไม่ -> แจ้งเตือนผู้ใช้




**Candidate:**

- **Speech-to-text (STT) model:** ใช้โมเดลที่รองรับภาษาไทย และมี latency/delay ต่ำเพื่อให้รองรับ near real-time/real-time มากที่สุด เช่น OpenAI Whisper, PyThaiASR. (to be selected later)

- **Trained Model:** จาก base model NLP ที่ถูก pre-trained ด้วย datasets ภาษาไทย เช่น WangchanBERTa, PhayaThaiBERT, Pathumma LLM. (to be selected later)

**3. Data Plan**

ข้อมูลหลักจะมาจากชุดข้อมูลภาษาไทย 2 แหล่ง ได้แก่ Scam Dialogue Thai Translated ซึ่งเป็นบทสนทนาที่มีคำกำกับ Scam / Not Scam อยู่แล้ว (อ้างอิง: Hugging Face) และ Thai Call Center Call Log Dataset ซึ่งเป็นข้อมูลบทสนทนา Call Center ภาษาไทย (อ้างอิง: Kaggle)

ก่อนนำมาใช้จะตรวจสอบรูปแบบ คำกำกับ ข้อมูลซ้ำ และข้อความที่ไม่สมบูรณ์ แล้วปรับข้อมูลทั้งสองแหล่งให้อยู่ในรูปแบบเดียวกัน โดยกำหนดผลลัพธ์เป็น Scam และ Not Scam และใช้เฉพาะข้อมูลที่สามารถจัดกลุ่มได้อย่างชัดเจน ส่วนข้อมูลที่กำกวมจะไม่นำมาใช้

จากนั้นจะแบ่งข้อมูลสำหรับฝึกและทดสอบเป็น รายบทสนทนา เพื่อไม่ให้ข้อความจากบทสนทนาเดียวกันปะปนอยู่ทั้งสองส่วน ทั้งนี้ Scam Dialogue Thai Translated เป็นข้อมูลที่แปลมาจากภาษาอังกฤษ จึงอาจมีภาษาและสถานการณ์ที่ต่างจากการหลอกลวงในไทยจริง ส่วน Thai Call Center Call Log Dataset ยังต้องตรวจสอบว่าคำกำกับเดิมสามารถแบ่งเป็น Scam / Not Scam ได้ชัดเจนเพียงใดก่อนนำมาใช้ร่วมกัน.

**4. การใช้งานและผลลัพธ์**

โครงงานนี้มีเป้าหมายพัฒนาเป็น Mobile Application สำหรับตรวจจับสายโทรศัพท์มิจฉาชีพ โดยวิเคราะห์จากเนื้อหาที่เกิดขึ้นระหว่างการสนทนา แทนการตรวจสอบจากหมายเลขโทรศัพท์เพียงอย่างเดียว

เมื่อผู้ใช้กำลังสนทนาทางโทรศัพท์ ระบบจะนำเสียงสนทนามาแปลงเป็นข้อความด้วย Speech-to-Text และวิเคราะห์ข้อความที่เกิดขึ้นอย่างต่อเนื่องด้วยโมเดลที่ฝึกไว้ เพื่อจำแนกว่าบทสนทนานั้นเป็น Scam หรือ Not Scam หากตรวจพบรูปแบบการสนทนาที่เข้าข่ายมิจฉาชีพ ระบบจะแจ้งเตือนผู้ใช้ระหว่างสายแบบ Near real-time เพื่อให้ผู้ใช้สามารถตัดสินใจได้ก่อนให้ข้อมูลสำคัญหรือดำเนินการตามที่มิจฉาชีพร้องขอ

กลุ่มผู้ใช้งานหลักคือ ผู้ใช้สมาร์ตโฟนทั่วไป โดยเฉพาะผู้ที่อาจไม่สามารถแยกแยะสายมิจฉาชีพจากหมายเลขหรือรูปแบบการโทรได้ทันที แนวคิดนี้สามารถต่อยอดร่วมกับระบบ Call Screening ของสมาร์ตโฟน ผู้ให้บริการเครือข่าย หรือระบบป้องกันการฉ้อโกงอื่น ๆ ได้ในอนาคต