กลุ่ม Phoebe

อย่าเอาเงินชั้นไป



Scam Call Alert

แจ้งเตือนสายมิจฉาชีพ จากสิ่งที่ปลายสายพูด

สมาชิกกลุ่ม



ภูดิสพัฒน์ ศรีสุพรรณ์

6620503535



คงยุทธ คล่องแคล่ว

6620501303

สิ่งที่จะนำเสนอ

01
Problem

02
System

03
Datasets

04
Models

05
Evaluation

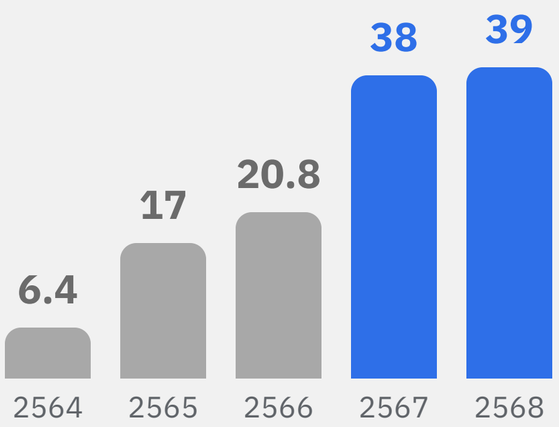
06
Application

07
Conclusion

Demo

เบอร์เปลี่ยนได้ แต่บทหลอกยังเหมือนเดิม

สายหลอกลวงในไทย (ล้านสาย) **×6 ใน 4 ปี**



Whoscall รายงานประจำปี 2564–2568 [12]

ความเสียหายจากคดีออนไลน์

38,105

ล้านบาท

636,482 คดี เฉลี่ย 976 คดีต่อวัน

1 ม.ค. 68 – 13 ต.ค. 69

ประเภทคดีที่พบมากที่สุด

สินค้าและบริการ	**62%**
เสนอผลประโยชน์	**15%**
การจ้างงาน	**8%**
แอบอ้างเป็นบุคคลอื่น	**8%**
การเงินและการลงทุน	**4%**

วิธีเดิมมี Pain Point บล็อกเบอร์ได้ก็ต่อเมื่อมีคนรายงานแล้ว

แนวคิดเรา ใช้ Machine Learning ช่วยฟังว่าปลายสายพูดอะไร แล้วเตือนระหว่างคุย

มองปัญหานี้เป็นโจทย์ ML problem

Scam / Fraud Call Classification

จำแนกสายโทรเข้า จากข้อความที่ได้ยินในสาย ว่าเป็น Scam (สายหลอกลวง) หรือ Not Scam (สายปกติ)

1. INPUT

ข้อความจากเสียงในสาย

เสียงถูกถอดเป็นตัวหนังสือ (STT)

2. MODEL

โมเดล NLP ที่เข้าใจภาษาไทย

เรียนรู้จากตัวอย่างสายหลอกและสายปกติ

3. OUTPUT

Scam / Not Scam

จากผลการ predict ของโมเดล (0...1) เกิน 0.5 ถือว่าเป็น Scam

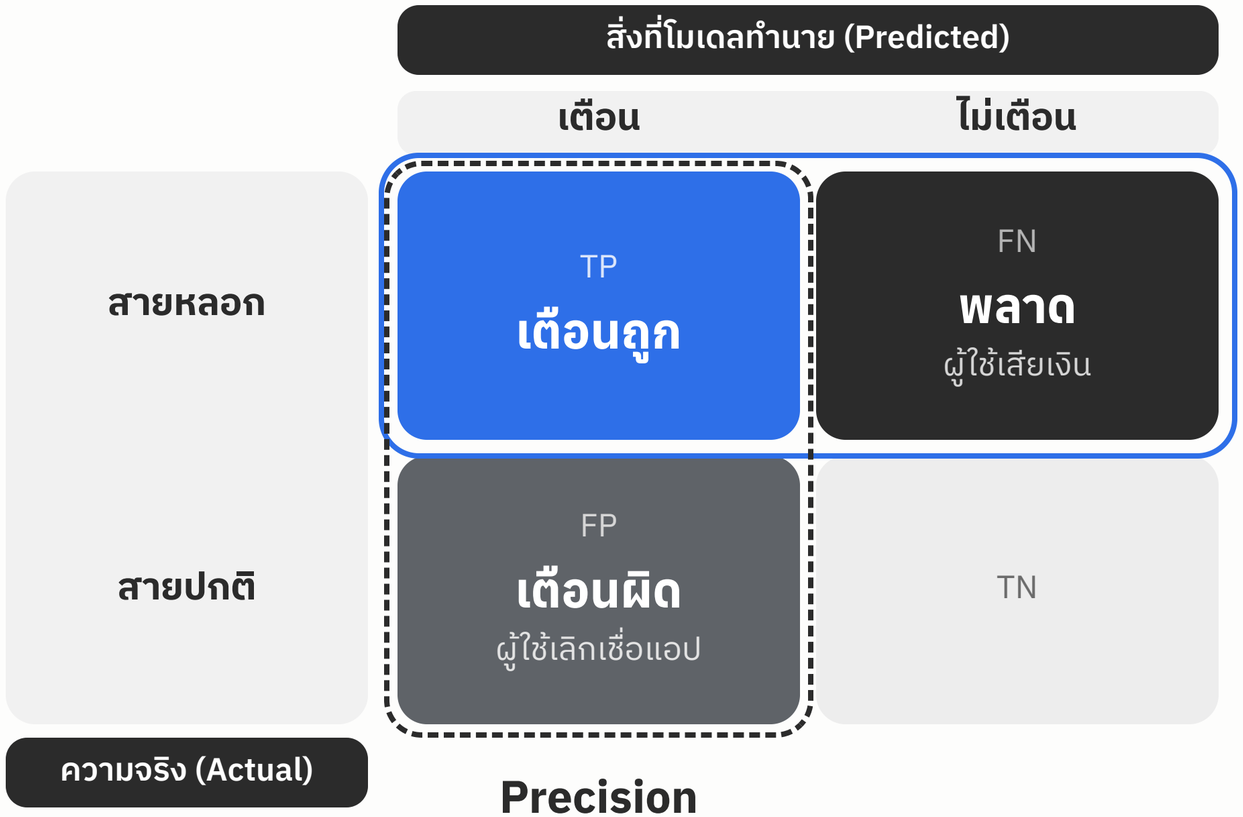
4. ACTION

เตือนผู้ใช้

แสดงแถบเตือนระหว่างสายว่ามีความเสี่ยง

ใช้ metric **Scam F1-Score**: จับสายหลอกให้ได้ และไม่เตือนสายปกติจนผู้ใช้รำคาญ

ทำไมวัดด้วย Scam F1



Recall

สายหลอกทั้งหมด จับได้กี่ %

Precision

ที่เตือน ถูกจริงกี่ %

F1-Score

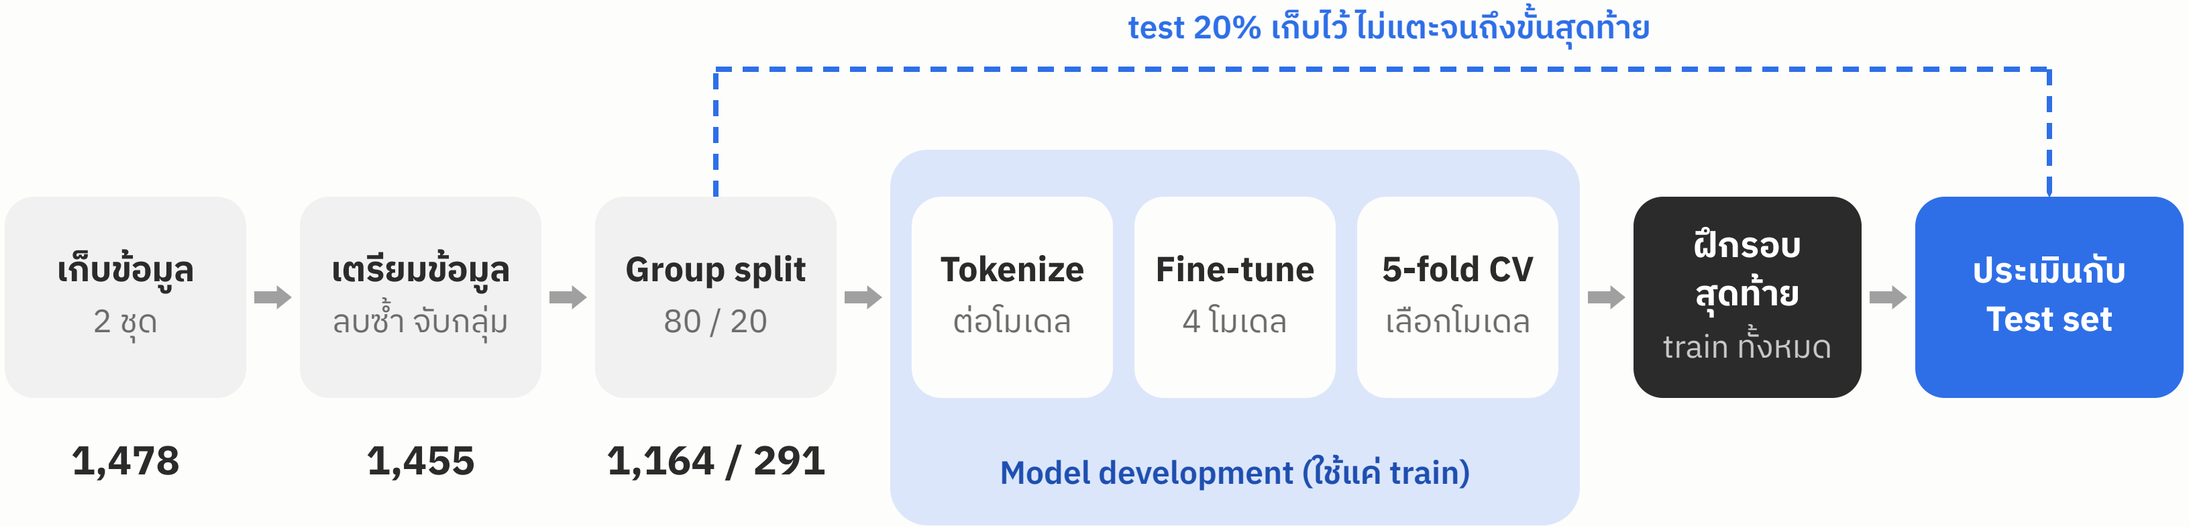
$2 \times P \times R / (P + R)$

ต่ำทันที ถ้าตัวใดตัวหนึ่งต่ำ

สถาปัตยกรรมระบบ



Development Pipeline



Datasets

1. Scam Dialogue Thai Translated

บทสนทนา

1,280

Scam 640 / Not Scam 640

สังเคราะห์จากบทสนทนาภาษาอังกฤษ **BothBosu/scam-dialogue**

แปลเป็นไทยด้วย Claude Sonnet 4.6

มี label เป็น Scam / Not Scam อยู่แล้ว

เผยแพร่บน Hugging Face โดย thirdExec

ตัวอย่าง Scam

"นี่คือเจ้าหน้าที่จอห์นสันจากสำนักงานประกันสังคม"
"หมายเลขประกันสังคมของคุณถูกระงับเนื่องจากมีกิจกรรมที่น่าสงสัย"

ตัวอย่าง Not Scam

"ฉันแค่อยากจะยืนยันว่าพัสดุของฉันจะถูกจัดส่งในวันนี้ประมาณเวลา 14.00-17.00 น."
"มีอะไรอีกไหมที่เราสามารถช่วยคุณได้?"

Datasets

2. Thai Call Center Call Log

บทสนทนา

198

Scam 73 / Not Scam 125

หมวดในแหล่งข้อมูล (จำนวน) → ป้ายที่ใช้

Scam (73)	Scam
General (49)	Not Scam
Official (37)	Not Scam
Verification-call (26)	Not Scam
Unknow (13)	Not Scam

ทุกหมวดที่ไม่ใช่ Scam นับเป็น Not Scam

ตัวอย่าง Scam

"พนักงานไปรษณีย์ โทรมาแจ้งว่าพัสดุของคุณถูกอายัด"

ตัวอย่าง Not Scam

"หวัดดี เราคิดถึงแก"
"คิดถึงเหมือนกัน"
"ไปเจอกันวันเสาร์ไหม"

Synthetic Data นี้เชื่อถือได้แค่ไหน

BOTHBOSU (2024) [4]

Llama-3-70B เขียนบทสนทนาอังกฤษ

1,600 บทสนทนา

→

THIRDEXEC (2026) [1]

Claude Sonnet 4.6 แปลเป็นไทย

ผ่าน distilabel และมี pipeline.yaml

→

ชุดหลักของเรา

1,280 บทสนทนาภาษาไทย

แปลเฉพาะ train split (1,280 จาก 1,600)

มีงานวิจัยใช้จริง

PoPETs 2026 ใช้ชุดต้นฉบับนี้ฝึกโมเดลจับ scam [3]

****ข้อพิจารณา****

ยังเป็นบทสนทนาจำลอง ไม่ใช่สายจริง

Data cleaning

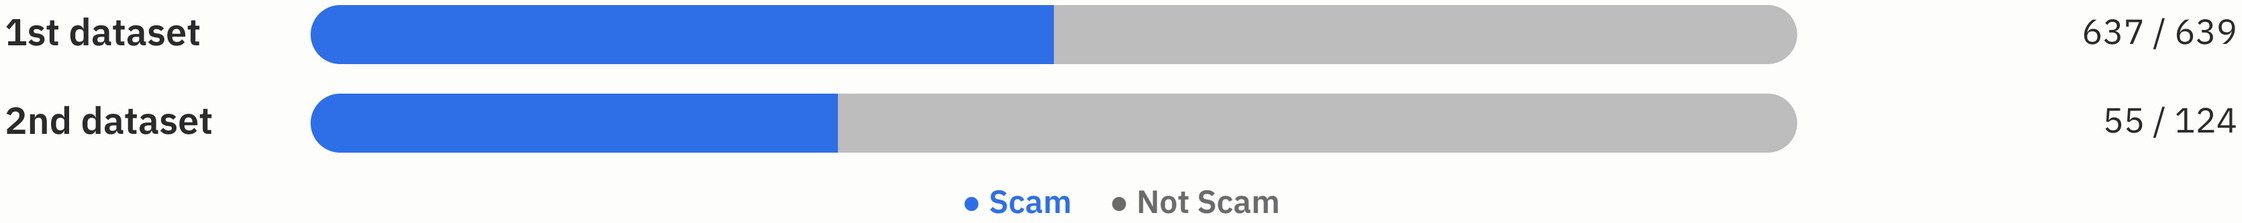
1,478
ข้อมูลดิบ

→

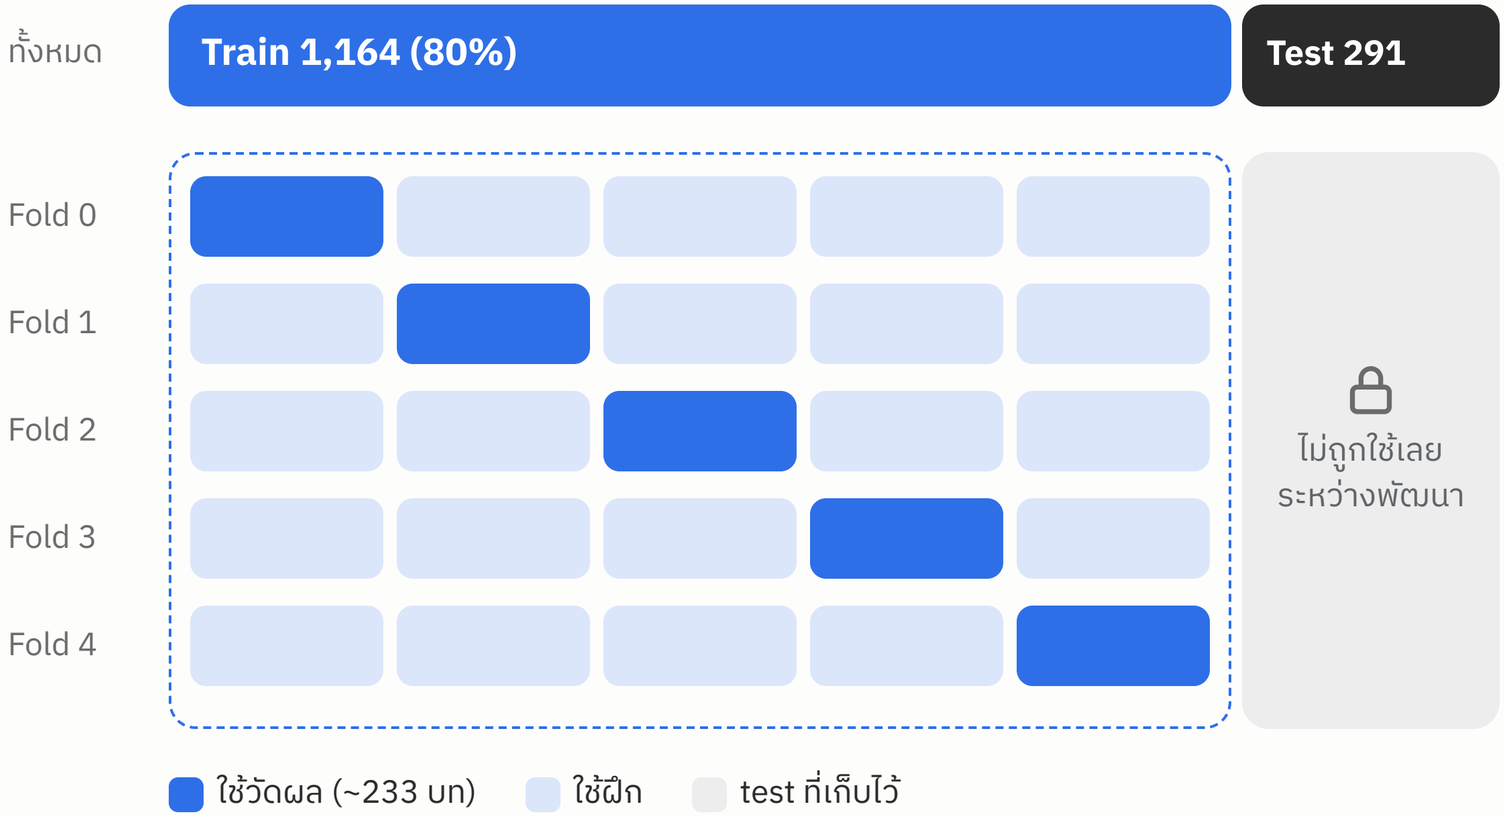
−23
ซ้ำ 20, ถูกตัด 3

→

1,455
พร้อมใช้



แบ่ง Train / Test และ 5 Folds



แยก test ก่อนทุกอย่าง

เก็บไว้วัดครั้งสุดท้าย ให้เหมือนข้อมูลที่ไม่เคยเห็น

ใช้ 5-Fold CV

แต่ละรอบฝึก 4 fold + validate กับอีก 1 fold

ทุกโมเดลใช้ fold ชุดเดิม

จึงเทียบกันได้ตรง ๆ

ทำไมใช้ StratifiedGroupKFold

Stratified

ทุก fold มีสัดส่วน Scam / Not Scam ใกล้เคียงข้อมูลเดิม คะแนนแต่ละ fold จึงเทียบกันได้

Group = กลุ่มของบทที่เหมือนกันมาก

บทสนทนาที่เขียนจากแม่แบบเดียวกัน (ต่างกันแค่ชื่อหรือรายละเอียดเล็กน้อย) รวมเป็น 14 กลุ่ม 37 บท ทั้งกลุ่มอยู่ฝั่ง train หรือ test ฝั่งเดียว ถ้าแยกกันโมเดลจะเจอของที่เคยเห็นแล้ว คะแนนจะสูงเกินจริง

Test แบ่งตามแหล่งด้วย

stratify ตามแหล่ง + label ให้ test มีทั้งสองชุดในสัดส่วนเดิม (255 / 36)

02 - DATASETs/scripts/4.split.py

```
strata = [r["source_dataset"] + ":"
          + r["label"] for r in records]
splitter = StratifiedGroupKFold(
  n_splits=5, shuffle=True,
  random_state=67)

# fold แรก = test 20%
train_idx, test_idx = next(
  splitter.split(records, strata, groups))

# 5 folds จาก train อย่างเดียว
for fold, (_, val) in enumerate(
  splitter.split(train, labels, train_groups)):
```

เตรียมข้อความก่อนเข้าโมเดล

ตอนฝึก (มีป้ายกำกับฝ่ายสนทนา)

```
Caller: …
Receiver: …
```

ตอนวัดผล / ในแอป (ไม่มีป้าย)

```
… …
… …
```

***ข้อจำกัดของโมเดล* บทสนทนาที่ยาวเกิน 510 tokens จนท้ายถูกตัด**



4 Candidate Models

1 / 2: โมเดลภาษาไทย ที่พัฒนาในไทย

VISTEC-depa AI Research Institute (2021) [5]

WangchanBERTa

RoBERTa ที่ฝึกด้วยข้อความภาษาไทยล้วน

Parameters	ข้อมูลฝึก	Vocab
106M	**78.5 GB**	**25k**

สร้างมาเพื่อ ภาษาไทยมีข้อมูลน้อย และโมเดลหลายภาษายังเข้าใจลักษณะภาษาไทยได้ไม่ดี

เราเลือกเพราะ เป็นมาตรฐานของงาน NLP ภาษาไทย

จุฬาฯ (ภาษาศาสตร์) × ClickNext (2023) [6]

PhayaThaiBERT

ต่อยอด WangchanBERTa ให้รู้จักคำต่างประเทศ

Parameters	ข้อมูลฝึก	Vocab
278M	**156.5 GB**	**249k**

สร้างมาเพื่อ อ่านคำอังกฤษที่เขียนปนในข้อความไทยได้ดีขึ้น

เราเลือกเพราะ บทหลอกมักมีชื่อหน่วยงานหรือคำอังกฤษปน

4 Candidate Models

2 / 2: แนวทางรุ่นใหม่ และโมเดลหลายภาษา

โครงการ HPLT ของยุโรป (2025) [7][8]

HPLT GPT-BERT Thai

โมเดลลูกผสม GPT + BERT ภาษาไทยล้วน

Layers	ข้อมูลฝึก	Vocab
24	**HPLT 3.0**	**32k**

สร้างมาเพื่อ ให้มีโมเดลเปิดของแต่ละภาษา ที่เรียนได้ทั้งเติมคำและเดาคำถัดไป

เราเลือกเพราะ เป็นตัวแทนสถาปัตยกรรมรุ่นใหม่

Facebook AI (2020) [9]

XLM-RoBERTa

RoBERTa ที่ฝึกพร้อมกัน 100 ภาษา รวมภาษาไทย

Parameters	ข้อมูลฝึก	Vocab
~270M	**2.5 TB**	**250k**

สร้างมาเพื่อ ใช้โมเดลเดียวได้กับหลายภาษา โดยไม่ต้องฝึกแยกทีละภาษา

เราเลือกเพราะ อยากรู้ว่าโมเดลเฉพาะไทยดีกว่าจริงไหม

เทียบ 4 โมเดลอย่างไรให้ยุติธรรม

1

ข้อมูลชุดเดียวกัน

train 1,164 บทสนทนา แบ่ง 5 folds เหมือนกันทุกโมเดล

2

ฝึกแบบเดียวกัน

AdamW, batch 16, 3 epochs, seed 67

3

วัดด้วยเกณฑ์เดียว

Scam F1 บนข้อความไม่มีป้ายผู้พูด เฉลี่ยจาก 5 folds

4

เลือกแล้วค่อยเปิด test

ตัวที่ดีที่สุดฝึกใหม่บน train ทั้งหมด แล้ววัดบน test ครั้งเดียว

สิ่งที่ต่างกันคือ **ตัวโมเดล**

แผนการทดลอง เทียบกับที่ทำจริง

45 / 75 รอบที่วางแผนไว้

WangchanBERTa (6 config)	× 6
PhayaThaiBERT 3e-5	
HPLT 3e-5	
XLM-R 3e-5	
3 ตัวหลัง (LR 2e-5, 5e-5)	× 6 ไม่ได้รัน

1 ช่อง = 1 fold (3 โมเดลหลังรันไม่ครบด้วยข้อจำกัดด้านเวลา และฮาร์ดแวร์)

selection/workflow.py

```
MODELS = ("wangchanberta",
  "phayathaibert", "hplt", "xlmr")
RATES = (2e-5, 3e-5, 5e-5)
FOLDS = range(5)

for model in MODELS:
 for pooling in POOLING[model]:
  for lr in RATES:
   for fold in FOLDS:
    rows.append({…})
if len(rows) ≠ 75:
  raise ValueError(…)
```

ตั้งค่าการฝึกให้เท่ากันทุกโมเดล

Loss
Cross-Entropy

Optimizer
AdamW

Learning rate
2e-5 – 5e-5

Warmup
linear → คงที่

Batch
16 = 4 × 4

Weight decay / clip
0.01 / 1.0

Class weight
ไม่ใช้ (สมดุลแล้ว)

GPU
T4, FP16

training/trainer.py

```
optimizer = AdamW(groups,
    lr=opt_cfg["learning_rate"],
    betas=(opt_cfg["beta1"], opt_cfg["beta2"]),
    eps=opt_cfg["epsilon"])
scaler = torch.amp.GradScaler(device.type,
    enabled=precision == "fp16")

losses = F.cross_entropy(logits.float(),
    labels, reduction="none")
clip_grad_norm(model.parameters(), max_norm)
```

ผล Cross-Validation



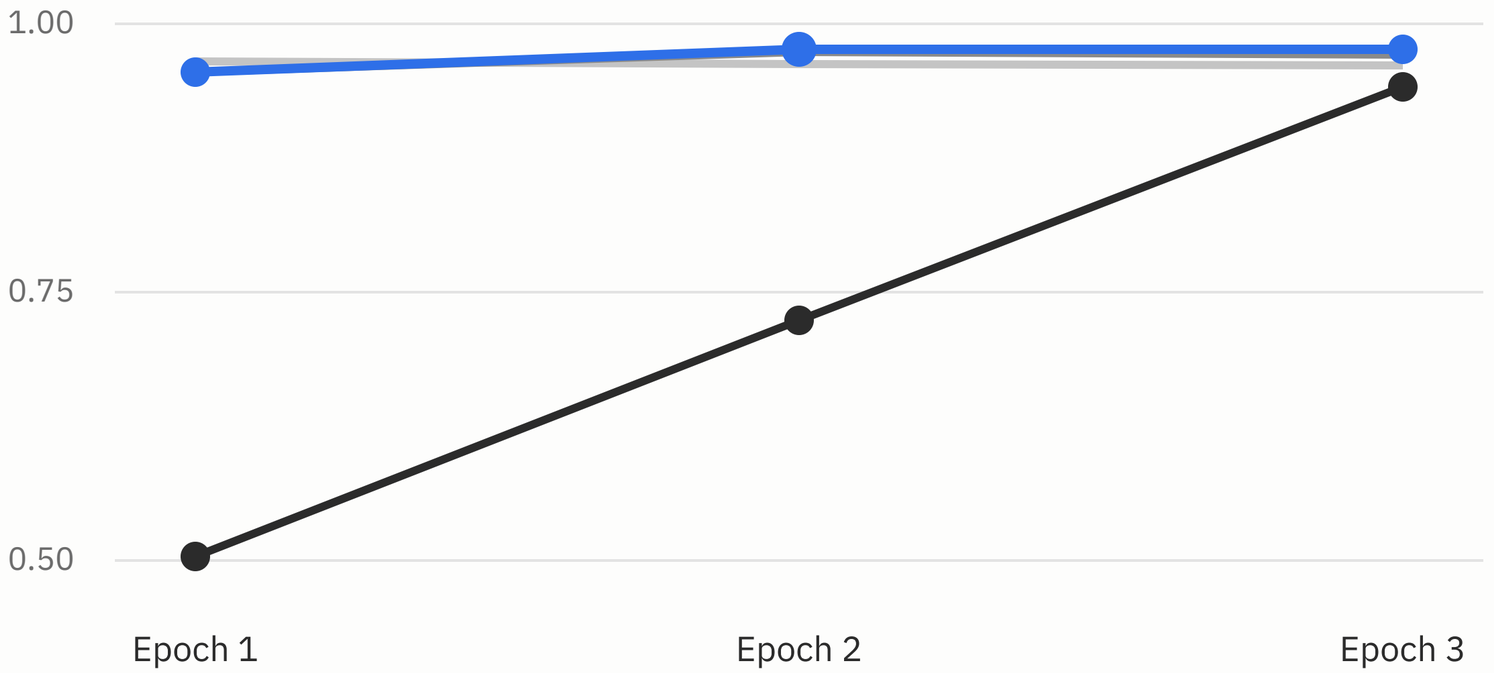
Role-free Scam F1 เฉลี่ย 5 folds ที่ LR 3e-5 (แกนเริ่มที่ 0.90)

ห่างอันดับสอง

0.003

ต่างกันน้อยกว่าความแกว่งระหว่าง fold จึงยังบอกไม่ได้ว่าเหนือกว่าชัดเจน

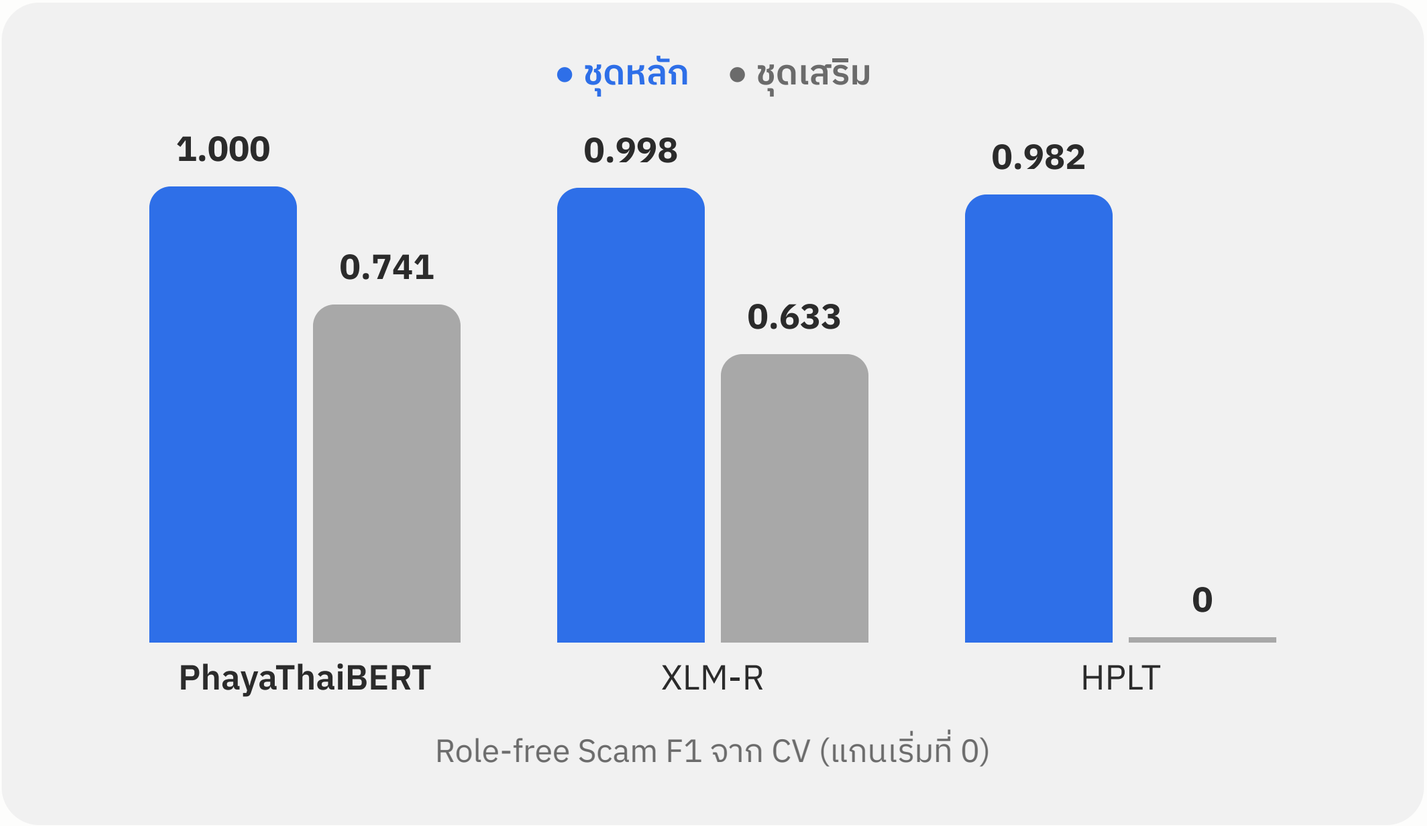
ฝึกกี่ epoch ถึงจะพอ



- **PhayaThaiBERT**
- XLM-R
- WangchanBERTa
- HPLT

HPLT ต้องฝึกนานกว่าตัวอื่น ส่วน PhayaThaiBERT ดีที่สุดที่ epoch 2

แยกดูทีละแหล่งข้อมูล



Role-free Scam F1 จาก CV (แกนเริ่มที่ 0)

26 / 26

จุดที่ PhayaThaiBERT ทายผิด อยู่ในชุดเสริมทั้งหมด

ชุดเสริมใน train 143 รายการ (FP 17, FN 9)

โมเดลที่เลือก

PhayaThaiBERT

LR 3e-5, 2 epochs, ฝึกด้วยชุดหลัก, threshold 0.5

Scam F1 ใน CV	บทสนทนาที่ใช้ฝึกรอบสุดท้าย	เวลาฝึกรอบสุดท้าย (นาที)
0.977	**1,021**	**41.5**

ผลจริงบน Test Set

Scam F1

0.974

Precision **0.978**

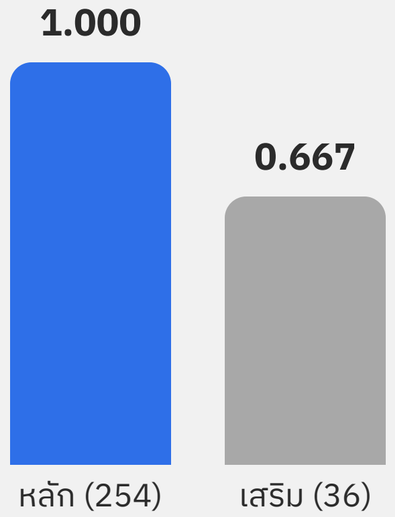
Recall **0.971**

Accuracy **0.976**

Confusion matrix (290 รายการ)

	ทาย ปกติ	ทาย Scam
จริง ปกติ	150	3
จริง Scam	4	133

Scam F1 ตามแหล่งชุดข้อมูล



โมเดลพลาดตรงไหน

4 หลอกจริง แต่ไม่เตือน

“คุณมีพัสดุตกค้าง ที่ต้องรีบจ่ายค่าธรรมเนียมทันทีไม่งั้นของจะโดนทำลาย”

p(Scam) = 0.16

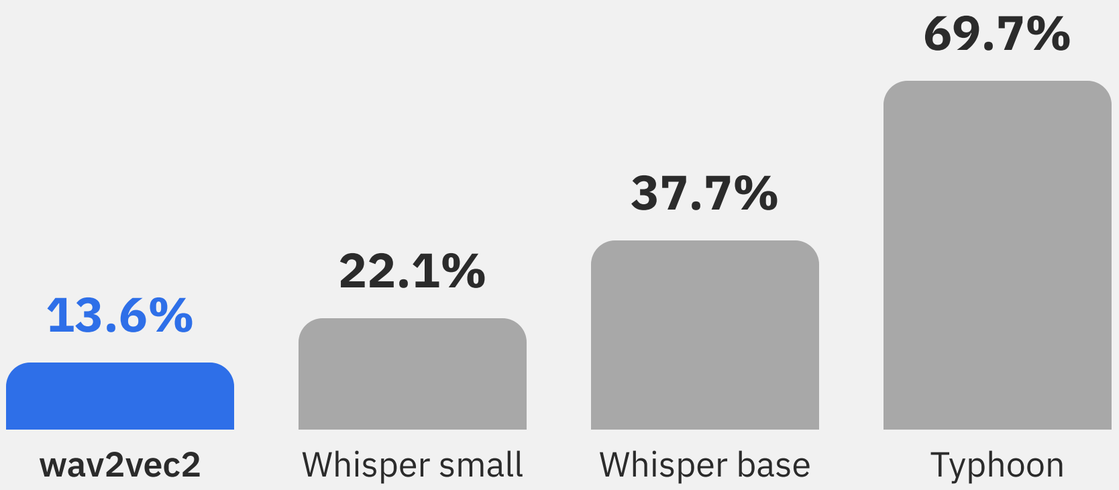
3 สายปกติ แต่เตือน

“โทรจากกรมควบคุมโรค แจ้งว่าคุณเป็นผู้สัมผัสใกล้ชิด COVID-19”

p(Scam) = 0.65

ทั้ง 7 ครั้งมาจากชุดเสริม และเป็นบทสนทนาสั้น ๆ เพียง 5–59 tokens

เลือกตัวถอดเสียง (STT)



CER ยิ่งต่ำยิ่งดี (FLEURS Thai 35 คลิป [11])

ความเร็ว (real-time factor)

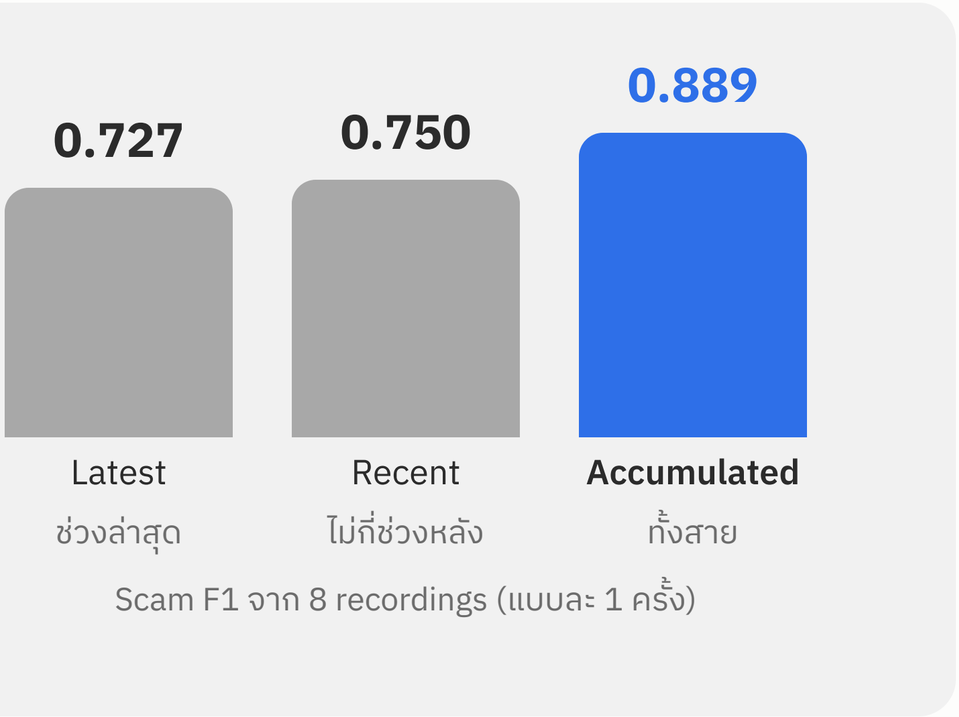
0.03×

เสียง 1 นาที ถอดเสร็จในราว 2 วินาที

แม่นและเร็วที่สุด แต่ใช้หน่วยความจำ GPU มากที่สุด

CER คือสัดส่วนตัวอักษรที่ถอดผิด (ทดสอบ 3 รอบ สำเร็จครบ 420 / 420 คลิป)

ระหว่างสาย ควรให้โมเดลอ่านช่วงไหน

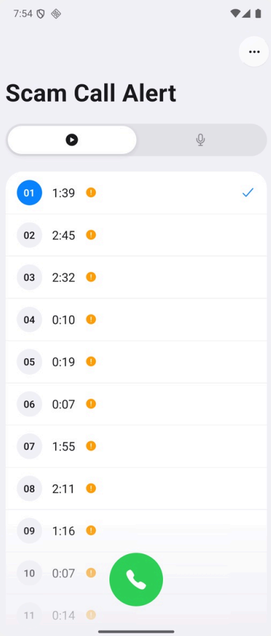


prototype/service/core.py

```python
if self.approach == "latest":
  predictive = new_speech
elif self.approach == "recent":
  predictive = "".join(
    x["text"] for x in segments[-n:])
else:  # accumulated
  predictive = self.transcript

# ตัดเหลือท้ายสุด ≤ 510 tokens
context, omission = \
  self.context_builder(predictive)
```

ใช้งานจริงเป็นอย่างไร



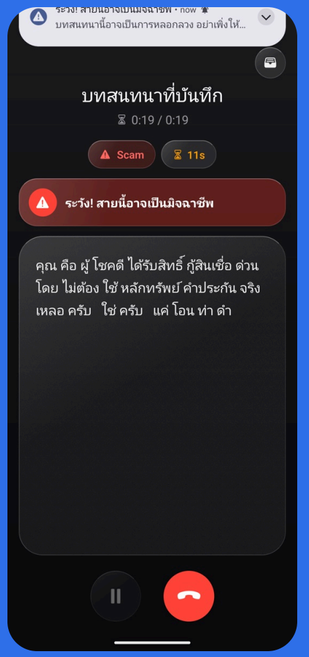
1

เลือกบทสนทนา



2

รับสาย



3

ขึ้นเตือนทันที

เจอ Scam ครั้งแรก แถบเตือนจะค้างไว้ตลอดสาย และทำงานได้แม้แอปอยู่เบื้องหลัง

ทดสอบว่าระบบทำงานได้จริง

รันพร้อมกันได้

STT + โมเดล ใช้หน่วยความจำ GPU ≈ 3.3 GB

สายหลอก → เตือน

เตือนที่นาที 0:47 พร้อม notification

สายปกติ → เงียบ

Not Scam ครบ 21/21 ครั้ง

ไมโครโฟนสด

ถอดเสียงและเตือนได้แบบสด

เสียงทดสอบสร้างด้วย text-to-speech จากบทสนทนาใน train จึงเป็นการเช็กว่าระบบทำงานได้ ยังไม่ใช่การวัดผลทั้งระบบ

สิ่งที่ยังทำไม่ได้

ข้อมูลเป็นบทสนทนาจำลอง
ยังไม่ได้ลองกับสายจริง

ทดลองได้ไม่ครบแผน
45 จาก 75 รอบ และใช้ seed เดียว

อ่อนกับข้อมูลต่างแหล่ง
ชุดเสริม F1 0.667 บน test

บทสนทนายาวถูกตัดท้าย
30% ของ Scam เกิน 510 tokens

STT วัดบนเสียงอ่าน
ไม่ใช่เสียงโทรศัพท์จริง

ยังไม่มีผลระดับระบบ
รันบน emulator ไม่ใช่มือถือจริง

Conclusion & Future improvements

แยกบทสนทนาหลอกได้ดี

Scam F1 0.974 บน test

ยังพลาดกับบทสนทนาสั้น

และข้อมูลต่างแหล่ง

แอปต้นแบบใช้ได้ครบวงจร

เสียง → ข้อความ → เตือน

ก้าวต่อไป: ลองกับเสียงสนทนาจริง, ฝึกด้วยข้อมูลหลายแหล่ง, วัดผลทั้งระบบ และย้ายโมเดลไปรันบนมือถือ

DEMO



Role-free Scam F1 ทุก configuration (mean ± SD, 5 folds)

Configuration	Epoch 1	Epoch 2	Epoch 3
Wangchan max, 2e-5	0.9623 ± 0.0118	0.9624 ± 0.0091	0.9606 ± 0.0054
Wangchan mean, 2e-5	0.9637 ± 0.0174	0.9519 ± 0.0117	0.9511 ± 0.0138
Wangchan max, 3e-5	0.9654 ± 0.0104	0.9625 ± 0.0120	0.9616 ± 0.0086
Wangchan mean, 3e-5	0.9607 ± 0.0115	0.9543 ± 0.0140	0.9544 ± 0.0098
Wangchan max, 5e-5	0.9636 ± 0.0141	0.9623 ± 0.0138	0.9623 ± 0.0138
Wangchan mean, 5e-5	0.9562 ± 0.0127	0.9542 ± 0.0115	0.9542 ± 0.0081
PhayaThaiBERT 3e-5	0.9556 ± 0.0247	**0.9768 ± 0.0129**	0.9760 ± 0.0113
HPLT 3e-5	0.5036 ± 0.1788	0.7244 ± 0.2759	0.9412 ± 0.0305
XLM-R 3e-5	0.9552 ± 0.0316	0.9736 ± 0.0057	0.9707 ± 0.0126

ฝึกด้วยชุดหลัก วัดผลกับทั้งสองแหล่ง (ที่มา: selection/cv_results.csv)

Supplemental Scam F1 รายย fold (role-free)

Fold	0	1	2	3	4
N (Not Scam / Scam)	20 / 12	22 / 9	18 / 7	23 / 9	16 / 7
PhayaThaiBERT (epoch 2)	0.750	0.667	0.933	0.640	0.714
XLM-R (epoch 2)	0.727	0.625	0.667	0.700	0.444
HPLT (epoch 3)	0.000	0.000	0.000	0.000	0.000

Primary F1

PhayaThaiBERT 1.000 ทุก fold, XLM-R 0.995–1.000, HPLT 0.922–1.000

PhayaThaiBERT pooled confusion

Supplemental [[TN 82, FP 17], [FN 9, TP 35]]

ป้ายผู้พูด เวลาฝึก และการตัดข้อความ

Model	Role-free F1	Marked F1	เวลาฝึก 5 folds	Scam ยาวเกิน budget
PhayaThaiBERT	0.9768	0.9791	97 นาที T4	30.0% (510)
XLM-R	0.9736	0.9718	149 นาที T4+CPU	27.5% (512)
HPLT	0.9412	0.9596	55 นาที T4	1.0% (512)

ป้ายผู้พูด

ถอดป้ายผู้พูดออก คะแนน PhayaThaiBERT เปลี่ยนแค่ −0.002 ± 0.009

เวลาฝึก

รวม I/O และ setup และ hardware ต่างกัน จึงเทียบความเร็วตรง ๆ ไม่ได้

รายการอ้างอิง

[1] thirdExec, Scam Dialogue Thai Translated, Hugging Face, 2026.

[2] Jxxn03X, Thai Call Center Call Log Dataset, Kaggle, 2025.

[3] I. Hossain et al., “AI-in-the-Loop: Privacy Preserving Real-Time Scam Detection…,” PoPETs 2026(1), pp. 87–114.

[4] BothBosu, Scam Dialogue, Hugging Face, 2024.

[5] L. Lowphansirikul et al., “WangchanBERTa,” arXiv:2101.09635, 2021.

[6] P. Sriwirote et al., “PhayaThaiBERT,” ACM TALLIP, 2025 (arXiv:2311.12475).

[7] L. G. G. Charpentier, D. Samuel, “GPT or BERT: why not both?,” BabyLM @ CoNLL, 2024.

[8] S. Oepen et al., “HPLT 3.0,” arXiv:2511.01066, 2025.

[9] A. Conneau et al., “Unsupervised cross-lingual representation learning at scale,” ACL, 2020.

[10] Z. Li et al., “Synthetic Data Generation with LLMs for Text Classification: Potential and Limitations,” EMNLP, 2023.

[11] A. Conneau et al., “FLEURS,” arXiv:2205.12446, 2022.

[12] Whoscall/Gogolook Thailand annual reports 2021–2025, via The Nation (2023, 2025) and Thai Newsroom (2026).

[13] ศปอส.ตร. (ตำรวจไซเบอร์), สถิติความเสียหายสะสม 1 ม.ค. 68 – 13 ต.ค. 69, thaipoliceonline.go.th (เข้าถึง 14 ต.ค. 69).

[L02] Pattern Recognition L02_Dataset Management and Data Quality (PDF p.49, 53–54)

[L05] Pattern Recognition L05_Model Selection & Hyperparameter Tuning (PDF p.11, 14–15, 35–36)

[L06] Pattern Recognition L06_Experimental Design and System Evaluation (PDF p.6, 12, 23, 35)